

Анализ литературы

Начальные определения

В данной работе мы определяем репетиторство как форму дополняющего основную (обязательную) школьную программу частного (подразумевающего материальное вознаграждение) образования, существующую в условиях централизованных экзаменов, значительно влияющих на дальнейшие карьерные и образовательные перспективы их участников.

Услуги такого рода, называемые социологами и экономистами «теневым образованием» (Stevenson, Baker (1992)) их способности компенсировать недостатки государственной системы образования, были впервые широко освещены в западной литературе в контексте стран, имплементировавших централизованное тестирование с целью обеспечения беспристрастного отбора в престижные университеты (Макеев, 2020) Тем не менее, множество работ оценивали эффективность сей практики, не принимая во внимание механизмы ценообразования — во многом из-за слабой степени развития платформенной экономики в рассматриваемые годы. После введения Единого государственного экзамена в России объём рынка на территории этой страны оказался рекордно велик; Kozar (2013) пишет: *«since 2009, university admission in Russia has been based on the results of standardised national exams (known as Unified State Exams, or USE), which are now used nationwide and are compulsory. This move has had drastic implications for the educational system and has already given rise to various services assisting in examination preparation (Prakhov & Yudkevich, 2012)»*.

Поскольку репетиторство является услугой, качество которой можно оценить только после ряда повторяемых взаимодействий с исполнителем, модели рынка репетиторских услуг неизбежно обязаны учитывать информационную асимметрию и связанные с ней методы сигнализирования. Репутационные сигналы (отзывы, рейтинги, ранжирование, принадлежность к университету) и «сарафанное радио» должны влиять на цену в значительной степени (Козар,

2013), (Макеев, 2020).

Кобахидзе (2018), утверждает, что ценообразование на постсоветских рынках «теневого образования» преимущественно определяется социальными и культурными нормами и личными отношениями вместо простого рыночного равновесия, что приводит к делению рынка на несколько значимо различных сегментов, определяемых через мотивацию исполнителей.

Bray and Kwok (2003) демонстрируют, что рынок репетиторских услуг в Гонконге сегментирован по способу взаимодействия репетитора и его учеников (один на один, малая группа, массовый класс): есть свидетельства того, что рынок каждого вида взаимодействия может иметь собственную ценовую функцию.

Рассуждая об экономической постановке задачи моделирования рыночных цен услуг репетиторов, мы осознанно игнорируем вопросы оценок экономической эффективности данных услуг и их экстерналий; фокусом данной работы является оценка факторов спроса, отражённых в объявлениях, обладающих наибольшей «ликвидностью», определяемой через число успешных транзакций

Козар (2013) представляет количественный анализ свойств 32 московских репетиторов;

Макеев (2019) приводит описательную статистику данных, полученных в результате парсинга шести агрегаторов: «Ассоциация репетиторов», «Ваш репетитор», «Профи.Ру», «Виртуальная академия», «Репетит-центр» и «Репетитор.Ру», но не проверяет никаких гипотез о полученных наблюдениях статистически — среди выводов встречается следующее примечательное наблюдение: *«на цену влияет не только статус репетитора и его стаж, но и наличие отзывов, а также его способность преподавать сразу несколько предметов. Услуги “многостаночников” стоят дороже»*. Макеев (2020) приводит результаты неструктурированных глубинных интервью с 19 репетиторами и 9 клиентами оных; в этой работе встречается следующий вывод о

ценообразовании: «также был рассмотрен механизм ценообразования на рынке репетиторских услуг, который выражается в практически ультимативном назначении суммы

репетитором. Случаи торга исключаются из-за “сарафанного радио” — клиенты заранее знают цену и связываются с репетитором только в случае предварительного согласия».

Данные

Для сбора данных о рынке репетиторских услуг было решено использовать краулинг сайта profi.ru — эта платформа появляется в первых строках релевантных поисковых запросов. Прямой сбор по API оказался недоступен, поэтому были написаны:

1. скрейпер на Python, проходящий по страницам <https://profi.ru/hub/repetitor/profiles/> для сбора ссылок на все доступные профили репетиторов;
2. скрейпер на Python, использующий результаты предыдущего для сбора JSON-файлов с базовой информацией о репетиторе, включая перечень предоставляемых услуг, пол, текстовые описания, рейтинги и так далее.

В результате были получены свыше 130.000 JSON-файлов, описывающих репетиторов во всех областях, представленных на сайте. Полный список собранных полей представлен в Приложении 1.

Чтобы отобрать наиболее релевантных репетиторов, представленных в наиболее наполненных на ресурсе категориях, мы отфильтровали выборку по четырём направлениям: математика (ЕГЭ), русский язык (ЕГЭ), английский язык (ЕГЭ) и физика (ЕГЭ). Также была проведена фильтрация по факту наличия отзыва за последние 6 месяцев (период активной подготовки к экзаменам), являющимся признаком присутствия успешных транзакций за этот период — это необходимо для обеспечения соответствия указанных цен с действительными рыночными.

Анализ

После применения трёх фильтров (релевантные предметы, наличие отзыва за последние 6 месяцев, непустое значение пола) итоговая выборка содержит **1 413 профилей репетиторов и 2 092 пары «репетитор — предмет»**. Среди отобранных профилей доля мужчин и женщин практически равна (49,1 % и 50,9 % соответственно), что снимает опасения о гендерном перекосе на уровне выборочного дизайна.

Распределение часовой ставки сильно правоскошено: медиана составляет **2 500 Р/час**, нижний квартиль — 1 884 Р, верхний — 3 000 Р, максимум — 11 750 Р; коэффициент асимметрии равен 1,61. Логарифмирование цены приводит асимметрию к $-0,34$, что де-факто восстанавливает симметрию и делает обоснованным использование $\log(\text{price})$ в качестве зависимой переменной в эконометрической модели.

По распределению по предметам выборка существенно неравномерна: математика — 1 287 предложений (61,5 % от длинного файла), русский — 254 (12,1 %), английский — 206 (9,8 %), физика — 191 (9,1 %), информатика — 154 (7,4 %). При этом межпредметные различия медиан невелики (2 315–2 500 Р), и тест Краскелла–Уоллиса не отвергает гипотезу о равенстве медиан ($N = 1,35$; $p = 0,855$). Этот результат сам по себе показателен: в выборке именно «рыночно активных» репетиторов цена за час практически не зависит от того, к какому из пяти ЕГЭ-предметов готовит репетитор. Это контрастирует с распространённым представлением о премии «технических» предметов и ставит под вопрос наличие предметной сегментации рынка — в нашем случае сегментация, если она и есть, проходит не по направлениям подготовки.

Среди бинарных характеристик две почти не варьируются на активной подвыборке: верифицированный паспорт имеют 99,9 % репетиторов, дистанционная работа доступна у 98,9 % — оба признака, фактически «гигиенические» требования платформы для активного присутствия, и в эконометрический анализ они не включаются. Содержательную вариацию демонстрируют флаг готовности к выезду к ученику (31,6 % положительных значений) и принадлежность к одному из 20 ведущих российских вузов, определённая через подстрочный поиск в графе «Образование» (30,4 %). Доля выпускников топ-вузов (определённых через рейтинг Forbes, 2026) внутри

выборки распределена ожидаемо: МГУ — 113, ВШЭ — 58, МГТУ им. Баумана — 56, МФТИ — 40, при ощутимо меньшем представительстве МИФИ, МГИМО, СПбГУ, Финансового университета, РАНХиГС.

Парные одномерные сравнения часовой ставки выявляют умеренную, но статистически значимую (тест Манна–Уитни, $p = 0,002$) премию за выезд к ученику в размере 7,3 % к медианной ставке (2 500 vs 2 330 ₽). Премия за топ-вуз (4,2 %) и эффект пола (мужчины относительно женщин) индивидуально незначимы. Корреляционный анализ обнаруживает три пары сильно связанных регрессоров ($|\text{корр. Спирмана}| > 0.7$): (price_avg, price_max) ($r = 0,92$), (experience_years, years_on_site) ($r = 0,76$) и reviews_count years_on_site ($\rho = 0,73$). На стадии построения модели мы оставляем price_avg, experience_years и reviews_count, а years_on_site и price_max исключаем во избежание коллинеарности.

В качестве базовой модели оценивается регрессия с зависимой переменной $\log(\text{price_avg})$. Скошенные непрерывные регрессоры (experience_years, reviews_count, about_len, education_count, achievements_count) преобразуются $\log(1 + x)$; рейтинг (rating_avg) и бинарные дамми оставлены без преобразования. Пропуски рейтинга (16 % выборки) и описания (3 %) заполнены медианой/нулём с одновременным включением соответствующих дамми-флагов, что позволяет сохранять единую выборку $n = 1\,130$ во всех спецификациях и корректно сравнивать AIC/BIC.

Сравниваются пять спецификаций, отличающихся функциональной формой и составом регрессоров. Сводная таблица:

Модель	Форма	Adj R ²	AIC	BIC
M2	Log-линейная	0,048	1019,2	1039,3
M3	Log-log	0,130	918,6	943,7
M4	Log-log + сигнальные дамми	0,132	920,1	970,4
M5	M4 + флаг топ-вуза x log(опыт)	0,132	921,8	977,1

Минимум AIC и BIC достигается одновременно у спецификации M3.

Вложенный F-тест M3 → M4 (добавление шести бинарных и количественных дамми) даёт $p \approx 0,15$ — блок незначим как целое, что подтверждает выбор более экономной модели. Дополнение M5 эффектом взаимодействия не приносит прироста объяснённой дисперсии. $\text{Adj } R^2 \approx 13\%$ выглядит скромно, но соответствует устоявшемуся для хедонистических моделей репетиторских услуг диапазону: значительная доля цены определяется ненаблюдаемыми характеристиками — стилем преподавания, неформальной репутацией, специализацией на конкретных типах учеников.

Условие	Тест	Статистика / p-value	Вывод
1.Линейность	Ramsey RESET (степени 2, 3)	$F = 14,2$; $p < 0,001$	спецификация неполна — присутствует остаточная нелинейность
2.Отсутствие мультиколлинеарности	max VIF	1,69	ОК (порог 10)
3.Гомоскедастичность	Breusch–Pagan / White	$p = 0,026$ / $p < 10^{-8}$	отвергнута: применяем робастные ошибки НСЗ
4.Отсутствие автокорреляции	Durbin–Watson	2,02	ОК
5.Экзогенность		не тестируется напрямую	обсуждается ниже
6.Нормальность остатков	Jarque–Bera / Anderson–Darling	$p < 10^{-48}$ / $p < 10^{-7}$	отвергнута; при $n = 1\,130$ ЦПТ обеспечивает асимптотическую справедливость t- и F-тестов

Из шести условий два требуют комментариев. Гетероскедастичность строго отвергается обоими тестами, поэтому все стандартные ошибки и t -статистики далее представляются с поправкой HC3. Сравнение OLS и HC3 показывает, что направления значимости коэффициентов сохраняются, однако стандартная ошибка рейтинга вырастает с 0,097 до 0,109 — учёт гетероскедастичности здесь содержательно меняет уровень доверия.

Нормальность статистически отвергается, что для выборки в 1130 наблюдений практически неизбежно: достаточно небольшого числа дорогих репетиторов, чтобы тест Jarque–Bera зафиксировал отклонение. Однако асимметрия остатков близка к нулю, эксцесс умеренно положителен; благодаря центральной предельной теореме асимптотическая нормальность оценок МНК сохраняется, и точность p -значений не страдает.

Тест Ramsey RESET даёт основания подозревать остаточную нелинейность — вероятнее всего, в форме отдачи к рейтингу, который мы оставили линейным (по содержательным соображениям ограниченности шкалы 1–5). Оценка моделей с полиномами по `rating_avg` и сплайном по `log(experience_years)` (не приведена в основном тексте) даёт улучшение $\text{Adj } R^2$ не более чем на 1 п.п. при потере интерпретируемости — поэтому в качестве рабочей выбрана МЗ в её текущей форме.

Экзогенность регрессоров — единственная предпосылка, которую нельзя проверить в чисто наблюдательной кросс-секции. Главная угроза — обратная связь между ценой и числом отзывов: дороже выставленная услуга может объективно ограничивать поток клиентов и, как следствие, приток новых отзывов. Это потенциально сдвигает оценку коэффициента `log_reviews` вниз, что делает приведённую +8,7 % нижней границей истинной отдачи к репутационному сигналу.

Гипотеза	Тест	результат
H_0 : модель не значима в целом ($\beta_1 = \dots = \beta_k = 0$)	F-тест	$F = 43,0$; $p < 10^{-33} \rightarrow$ отвергаем
H_0 : блок сигнальных дамми незначим (M3 $\rightarrow$ M4)	вложенный F	$p \approx 0,15 \rightarrow$ не отвергаем
H_0 : $\beta_{\log_exp} = 0$	t-тест	$t = 3,51$; $p < 0,001 \rightarrow$ отвергаем
H_0 : $\beta_{\log_reviews} = 0$	t-тест	$t = 6,59$; $p < 0,001 \rightarrow$ отвергаем
H_0 : $\beta_{\log_about_len} = 0$	t-тест	$t = 4,28$; $p < 0,001 \rightarrow$ отвергаем
H_0 : $\beta_{rating} = 0$	t-тест	$t = 2,46$; $p = 0,014 \rightarrow$ отвергаем

Все четыре содержательных коэффициента модели M3 значимы на уровне 5 %; три из них — на уровне 0,1 %. Оцененная модель:

$$\text{Log}(\text{price}) = 5,85 + 0,049 \cdot \log(1 + \text{exp}) + 0,087 \cdot \log(1 + \text{rev}) + 0,268 \cdot \text{rating} + 0,033 \cdot \log(1 + \text{about})$$

Выводы

Цена на московском рынке ЕГЭ-репетиторства определяется почти исключительно накопленными репутационными сигналами. Эластичность цены по числу отзывов составляет +8,7 %, по продолжительности заявленного опыта — +4,9 %, увеличение рейтинга на один балл повышает цену на 26,8 %. Длина текстового описания, которую можно интерпретировать как мера усилий, вложенных репетитором в самопрезентацию (или как косвенный сигнал профессиональной зрелости), даёт +3,3 % за рост на 1 %. Этот результат согласуется с выводом Макеева (2019) о том, что на цену влияет не только статус репетитора и его стаж, но и наличие отзывов, и количественно его уточняет: вклад числа отзывов в формирование цены примерно вдвое превышает вклад заявленного стажа. Эффект также может быть нелинейным — например, в виде параболы ветвями вниз

2. Формальные регалии и предметная специализация в среднем не оплачиваются рынком. При контроле за основными репутационными переменными ни принадлежность к ведущему российскому вузу, ни предметные дамми, ни пол репетитора, ни число образовательных и достижений-записей не дают статистически значимого вклада в цену (вложенный F-тест $M3 \rightarrow M4$: $p \approx 0,15$). Иными словами, диплом топ-вуза становится, скорее, входным билетом на рынок, а не источником ценовой премии — что эмпирически подтверждает неформальное наблюдение Кобахидзе (2018) о доминировании сигналов репутации над сигналами происхождения в постсоветских системах теневого образования.

3. Предметной сегментации цен на «активной» подвыборке практически нет. Тест Краскелла–Уоллиса не отвергает гипотезу о равенстве медиан между ЕГЭ по математике, русскому, английскому, физике и информатике ($p = 0,855$). Это противоречит распространённой эвристике о «технической премии» и контрастирует с результатами Bray & Kwok (2003) для гонконгского рынка, где сегментация по способу взаимодействия даёт явно различные ценовые функции. По-видимому, на московском рынке профильная конкуренция в каждом из ЕГЭ-сегментов настолько высока, что вытесняет любую устойчивую предметную премию.

4. Объяснительная сила модели, что само по себе содержательно. В сочетании с результатами Кобахидзе (2018) о роли социальных и культурных норм и личных отношений это даёт основание полагать, что значительная часть ценовой дисперсии формируется в плоскости, не наблюдаемой в открытых данных платформы: личных рекомендациях, неформальных сетях, специализации на «олимпиадных» учениках и т. п.

Ограничения

Работа основана на кросс-секционных данных, что ограничивает возможность каузальной интерпретации полученных оценок: коэффициенты следует понимать как условные ассоциации, а не как причинные эффекты. Цена, наблюдаемая на платформе, является заявленной, а не реализованной; в отсутствие данных о фактических транзакциях нельзя исключить систематическое смещение между прайс-листом и фактической ставкой за час. Фильтр «отзыв за последние 6 месяцев» компенсирует это лишь частично, отбирая профили, чьи объявления относительно недавно сопровождались успешной транзакцией.

Возможные направления дальнейшей работы: оценка панельных моделей по нескольким срезам данных профильной платформы для разделения внутри- и межличностной вариации; включение модели формирования цены пакетных услуг (за курс, за месяц), которые мы намеренно отфильтровали при подготовке данных; более тонкая обработка переменной образования — вычленение уровня (бакалавриат / специалитет / магистратура / аспирантура) на основании длительности интервалов, что может объяснить часть остаточной дисперсии; сравнительный анализ с региональными подвыборками для проверки гипотезы о специфичности московского ценообразования.

Эта работа является первой попыткой эконометрически моделировать ценообразование на рынке репетиторских услуг в России, но работа, признаться честно, так себе. Но мы попытались.

ИИ-дисклеймер

При подготовке исследования использовался ассистент Claude (модель Opus 4.7 от Anthropic) через CLI-интерфейс Claude Code. Модель применялась исключительно для: написания и отладки кода обработки данных, построения визуализаций по заранее сформулированным требованиям, оформления стандартных эконометрических процедур и редакционной правки русскоязычного текста. Все содержательные решения — постановка исследовательского вопроса, выбор источника данных, формирование выборки, выбор переменных и интерпретация результатов — принимались нами.

Промты приводятся в сокращённой и канонической форме; реальный диалог состоял из десятков итераций.

1. *«Fix the ipynb to get a clean final dataset ready for EDA»* — для генерации шаблона очистки данных.
2. *«We need a second file structured as follows: tutor profile/features + subject + price per 1 row»* — для построения «длинного» формата.
3. *«Extract and add the following features... search for unis as in SQL like. Remove, using reviews table, any profiles that have no reviews in the past 6 months»* — для извлечения признаков и применения фильтра.
4. *«Take a look at the data without modifying the ipynb to see if we can extract the education level»* — для разведочного анализа без модификаций.
5. *«Start performing rigorous EDA — we will have to plot some graphs and provide descriptive statistics before performing econometric analysis»* — для построения EDA-ноутбука.

ИИ не использовался для: (а) скрейпинга и сбора первичных данных; (б) написания литературного обзора и формулировки исследовательской гипотезы; (в) выбора методологии (хедонистическая регрессия, набор тестов диагностики, форма выводов); (г) интерпретации количественных результатов в контексте предметной области; (д) оформления списка источников. Но использовался для написания этого текста, чтобы он посмотрел на историю чатов...

Источники

1. Stevenson, D. L., & Baker, D. P. (1992). Shadow Education and Allocation in Formal Schooling: Transition to University in Japan. *American Journal of Sociology*, 97(6), 1639–1657. <http://www.jstor.org/stable/2781551>
2. Kozar O. The Face of Private Tutoring in Russia: Evidence from Online Marketing by Private Tutors// *Research in Comparative and International Education-2013-vol 9, issue 1*.
<https://journals.sagepub.com/doi/10.2304/rcie.2013.8.1.74>
3. Макеев П. А. Репетиторство в России: описание явления на основе онлайн-платформ // *Journal of Institutional Studies* – 2019 - том 11, номер 4 – С. 106-121. <https://cyberleninka.ru/article/n/repetitorstvo-v-rossii-nelzya-uvidet-no-mozhno-uslyshat/viewer>
4. Kobakhidze, M. N. (2018). Teachers as Tutors: Shadow Education Dynamics in Georgia.
https://www.researchgate.net/publication/325396018_Kobakhidze_M_N_2018_Teachers_as_Tutors_Shadow_Education_Dynamics_in_Georgia
5. Mark Bray, Percy Kwok, Demand for private supplementary tutoring: conceptual considerations, and socio-economic patterns in Hong Kong, *Economics of Education Review*, Volume 22, Issue 6, 2003, Pages 611-620, ISSN 0272-7757, [https://doi.org/10.1016/S0272-7757\(03\)00032-3](https://doi.org/10.1016/S0272-7757(03)00032-3).
6. <https://www.forbes.ru/education/558029-lucsie-rossijskie-vuzy-2026-rejting-forbes>